

# 머신러닝 & 딥러닝 7

AI 학술동아리 <MLP>

# **- Index**

## **1. 합성곱 신경망**

# - 이미지 데이터 정규화 하기

이미지의 픽셀은 0~255 사이의 정숫값을 가짐

-> 이 경우 보통 **255로 나누어** 0~1 사이의 값으로 **정규화**


(표준화는 아니지만 양수 값으로 이루어진 이미지를 전처리할 때 널리 사용하는 방법)

# - Artificial Intelligence(인공지능)



**DL 라이브러리는 다른 ML 라이브러리와 다르게 GPU사용해서 ANN훈련**  
**- GPU는 벡터와 행렬 연산에 매우 최적화**

# 1. Artificial Neural Network(인공 신경망)



ANN을 줄여서 **NN**(Neural Network)라고도 함

ANN을 DL이라고도 함

**ANN**(Artificial Neural Network) = 인공 신경망

**DNN**(Deep Neural Network) = 심층 신경망  
= Deep Learning

-> Layer가 여러개


**SLP**(Single Layer Perceptron) = 단층 퍼셉트론

**MLP**(Multi Layer Perceptron) = 다층 퍼셉트론

보통 kernel size는 (3, 3), (5, 5)를 이용!

# 1. Convolution Neural Network(합성곱 신경망)

convolution 1



convolution 2



convolution 3




convolution 4



**filter**  $\supset$  **kernel**  
도장 weight, bias

보통은  
**filter = kernel**  
로 쓰임

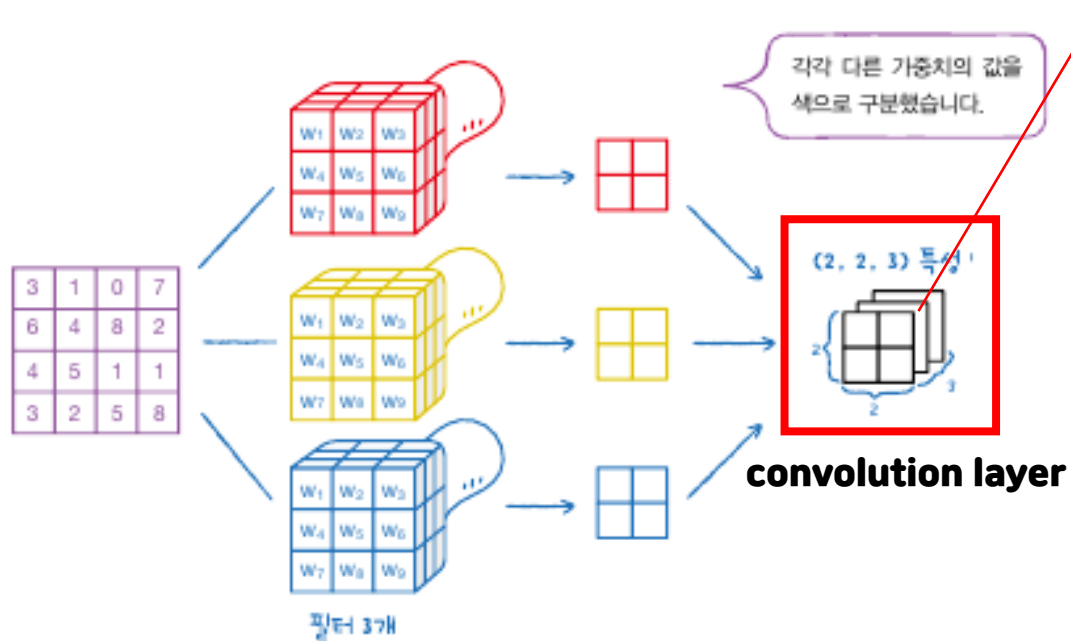


**kernel 크기는 hyperparameter**

**filter는 왼쪽에서 오른쪽으로, 위에서 아래로 이동**

**dense layer와 동일하게 단순히 input과 weight를 곱하지만, 2차원 형태를 유지하는 점이 다름**

# 1. CNN



feature map들

일반적으로 **1개 이상의 convolution layer**를  
가진 NN을 **CNN**이라고 부름

**CNN**은 특히 **이미지에 있는 특징**을 찾아  
**압축**하는 데 뛰어난 성능을 냄

기본 convolution 과정을 거쳐 feature map을  
만드는 경우를 valid padding이라고 함

**filter의 개수도 hyperparameter**


# - Padding(패딩)

convolution 과정을 거치고도 **output의 크기**를 **input과 동일**하게 만들 때 이용  
input 배열 주위를 가상의 원소로(0으로) 채움 = **same padding**  
0으로 채우기 때문에 **zero padding**


0	0	0	0	0	0
0	3	1	0	7	0
0	6	4	8	2	0
0	4	5	1	1	0
0	3	2	5	8	0
0	0	0	0	0	0



커널이 도장(필터)을 찍을 횟수를 늘려주기 위해서 입력 배열 주변을 가상의 원소로 채우는 것을 패딩이라고 합니다. 보통 패딩은 0으로 채웁니다.





(4:2:1)



(9:6:4)

패딩 여부에 따라 각 픽셀이 convolution에 참여하는 비율이 크게 차이 남  
-> **비율 차이를 줄이기 위해 same padding 이용**





# - Stride(스트라이드)

convolution 연산을 기본적으로 좌우, 위아래로 한 칸씩 이동  
이런 이동의 크기를 stride(스트라이드)라고 함

-> 두 칸씩(N 칸씩) 이동 가능

=> (5, 5) 크기의 입력에 (3, 3) 크기의 커널을 적용하면 결과는 (2, 2) 크기의 출력(그림으로 그려보기)

1보다 큰 stride를 사용하는 경우는 드물

# - Pooling(풀링)

보통 max pooling을 많이 이용!

average pooling은 feature map에 있는 중요한 정보를 (평균하여) 희석시킬 수 있기 때문


보통 (2, 2) pooling을 사용해 절반으로 줄임!

convolution layer에서 만든 feature map의 가로세로 크기를 줄이는 역할

- feature map의 개수(filter 개수만큼 생성됨)는 줄이지 않음(예: (2, 2, 3) → (1, 1, 3))

pooling에는 가중치가 없음, 도장을 찍은 영역에서 가장 큰 값을 고르면 max pooling(최대 풀링), 평균값을 계산하면 average pooling(평균 풀링)

convolution과 다르게 kernel이 겹치지 않고 이동(예: pooling의 크기가 (2, 2)이면 stride는 2, pooling의 크기가 (3, 3)이면 stride는 3)



보통 convolution에서 stride를 크게 하여 feature map의 크기를 줄이는 것보다 pooling을 통해 feature map의 크기를 줄이는 것이 더 나은 성능을 보임

# 1. CNN(흑백 이미지)

보통 convolution layer와 pooling layer은 거의 항상 함께 사용


$[2, 2, 3] \rightarrow [12, ]$

$[4, 4, 3] \rightarrow [2, 2, 3]$   
feature map의 개수는 변화 없음!

$(4, 4, 3)$  특성 맵



$(2, 2, 3)$  최대 풀링



$(12, )$  크기 입력



출력층

노드들 간의  
가중치와 편향  
activation function 적용


dense layer

이 부분을 그냥 FC Layer라고도 함  
또는 MLP라고 부르기도 함

pooling layer



convolution layer

input layer



input 이미지는 항상 깊이(채널) 차원이 있어야 함

# 1. CNN(컬러 이미지)



**kernel의 깊이는 input의 깊이와 같음**

**CNN은 너비와 높이는 점점 줄어들고  
깊이는 점점 깊어지는 것이 특징**

# - CNN 문제 1

## • 문제 1:

어떤 convolution layer가 컬러 이미지에 대해 5개의 filter를 사용해 same padding으로 convolution을 수행합니다. 그 다음 (2, 2) polling layer를 통과한 feature map의 크기가 (4, 4, 5)입니다. 이 경우 convolution layer에 주입된 input의 크기는 얼마인가요?

## • 정답 1:

변화 과정 :            ->            ->

# - CNN 문제 2

## • 문제 2:

다음과 같은 input에서 (3, 3) kernel과 valid padding으로 convolution을 수행합니다.  
filter의 개수는 1개이고 input의 깊이(채널)도 1개입니다. bias는 0이라고 가정합니다.  
이 convolution의 결과를 계산해 보세요.

(5, 5) 입력					(3, 3) 커널		
3	0	9	1	2	2	0	1
5	1	2	0	7	2	0	1
8	2	4	1	3	2	0	1
2	1	5	3	6			
4	1	6	2	7			

## • 정답 2:

- 계산 과정 생략

# - CNN 문제 3

## • 문제 3:

다음과 같은 (4, 4, 2) 크기의 feature map이 있습니다.  
(2, 2) max polling의 결과를 계산해 보세요.

9	10	6	2
2	1	4	8
9	0	7	1
8	8	3	3

6	7	2	10
1	2	6	9
2	6	3	5
4	3	5	2


## • 정답 3:

- 계산 과정 생략

# - Visualization(시각화)

weight visualization(가중치 시각화)

feature map visualization(특성 맵 시각화)



이를 **시각화**하면 CNN 동작 원리에 대한 통찰을 키울 수 있음